Исследование среды

Аржаев Павел
20 августа 2019

Tinkoff.ru

Задача исследование среды

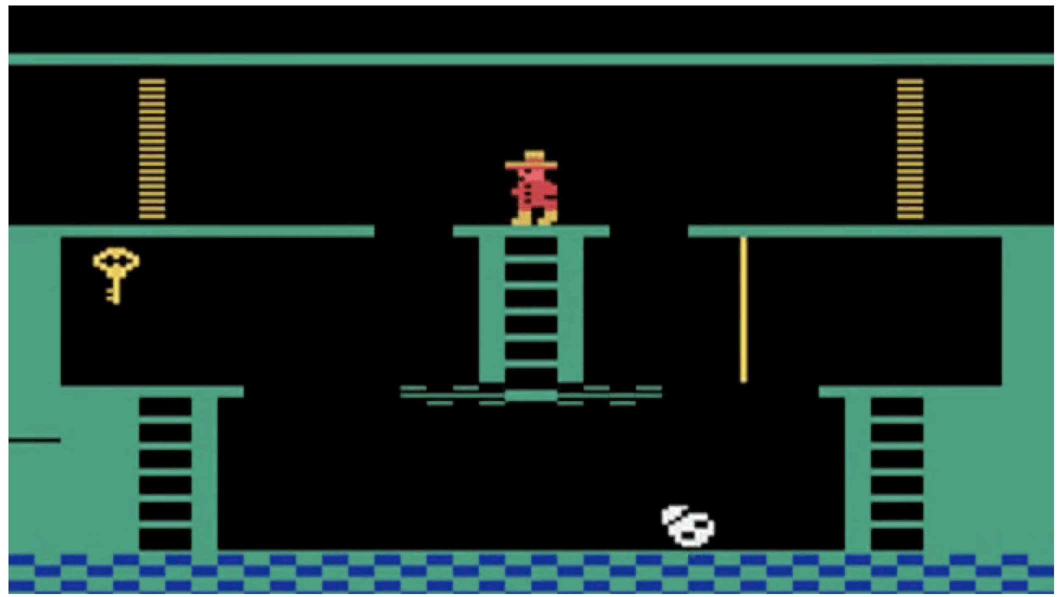

Exploration и Exploitation

Определения задачи исследования среды:

- Агент должен найти стратегию с высокой наградой, которая, в то же время, может потребовать долгой последовательности действий с низкой наградой.
- Агент должен выбрать между новым поведением и старым поведением с максимальной из исследованных наградой.

Оптимальная стратегия

Возможно ли ее найти?

Как определить оптимальность?

По возрастанию того, насколько сложно может быть явно проанализировать стратегию:

- Многорукий бандит (1-шаговый МП без состояния)
- Многорукий бандит с состоянием
- Небольшой, конечный МП
- Непрерывный, бесконечный МП

Многорукие бандиты

Есть несколько действий, каждое имеет некоторое распределение награды:

$$\mathcal{A} = \{\mathrm{pull}_1, \mathrm{pull}_2, \dots, \mathrm{pull}_n\}$$

$$r(a_n) \sim p(r|a_n)$$

Это распределение параметризовано, мы можем хранить belief об этих параметрах. Можно представить как POMDP со стейтом из этих параметров

$$r(a_i) \sim p_{\theta_i}(r_i) \quad \hat{p}(\theta_1, \dots, \theta_n)$$

Введем понятие regret для измерения оптимальности стратегии:

$$\mathrm{Reg}(T) = TE[r(a^\star)] - \sum_{t=1}^{T} r(a_t)$$

http://iosband.github.io/2015/07/28/Beat-the-bandit.html

Если решить этот POMDP, получим оптимальную стратегию исследования.

Однако, есть стратегии значительно проще.

Они асимптотически стремятся к regret ~ O(log(T))

Оптимизм

Будем хранить среднюю награду для дейст $\hat{\mu}_a$

$$\text{exploitation: pick } a = \arg\max \hat{\mu}_a$$

$$\text{optimistic estimate: } a = \arg\max \hat{\mu}_a + C\sigma_a$$

Идея: пробуем каждое действие, пока не убедимся, что оно не лучшее

Вариант коэффициента (Finite-time Analysis of the Multiarmed Bandit Problem):

$$a = \arg\max \hat{\mu}_a + \sqrt{\frac{2\ln T}{N(a)}}$$

Другое название - UCB (upper confidence bound)

Оптимизм в RL

$$r^+(\mathbf{s},\mathbf{a}) = r(\mathbf{s},\mathbf{a}) + \mathcal{B}(N(\mathbf{s})) \qquad a = \arg\max \hat{\mu}_a + \sqrt{\frac{2\ln T}{N(a)}}$$

Вводим модель плотност $p_\theta(\mathbf{s})$

Значение высоко, если состояние близко к уже посещенному

Функцию можно использовать для “подсчета” состояний

В случае дискретного пространства:

$$\underbrace{P(\mathbf{s})}_{\text{probability/density}} = \frac{\overbrace{N(\mathbf{s})}^{\text{count}}}{\underbrace{n}_{\text{total states visited}}} \qquad P'(\mathbf{s}) = \frac{N(\mathbf{s})+1}{n+1}$$

В случае непрерывного пространства

$$p_\theta(\mathbf{s}_i) = \frac{\hat{N}(\mathbf{s}_i)}{\hat{n}} \qquad p_{\theta'}(\mathbf{s}_i) = \frac{\hat{N}(\mathbf{s}_i)+1}{\hat{n}+1}$$

$$\hat{N}(\mathbf{s}_i) = \hat{n} p_\theta(\mathbf{s}_i) \qquad \hat{n} = \frac{1 - p_{\theta'}(\mathbf{s}_i)}{p_{\theta'}(\mathbf{s}_i) - p_\theta(\mathbf{s}_i)} p_\theta(\mathbf{s}_i)$$

Оптимизм в RL

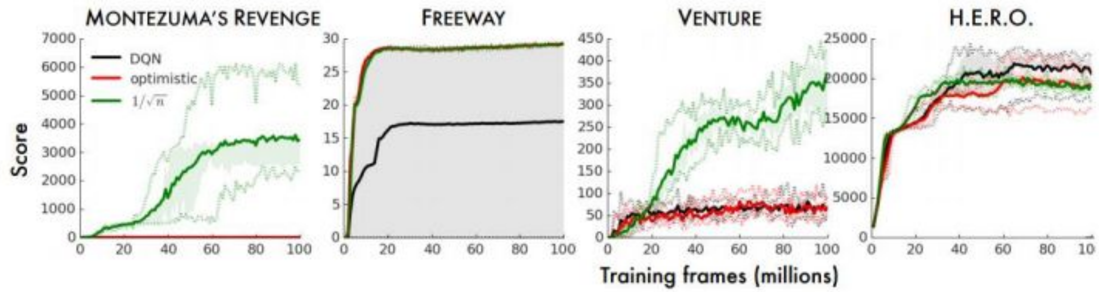

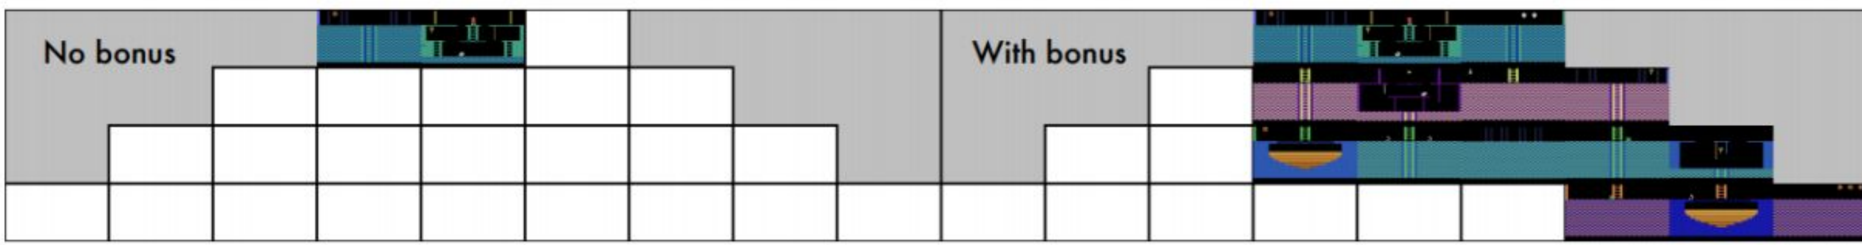

Bellemare et al. “Unifying Count-Based Exploration…”

Оптимизм: хэш

Можно считать посещения состояния, но в другом пространстве

Идея: сжать s с помощью хэш-функции $\varphi(s)$, считать $N(\varphi(s))$

Стейты с одинаковыми хэшами должны быть близки

Один из вариантов получения такой функции - вариационный автоэнкодер

(Exploration: A Study of Count-Based Exploration for Deep Reinforcement Learning)

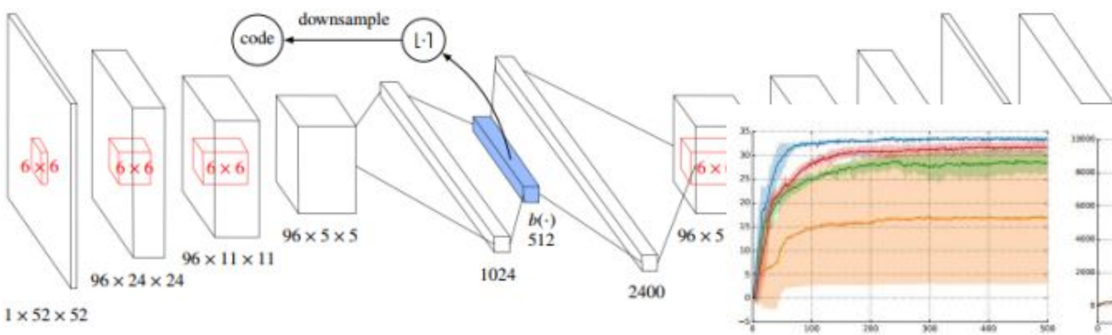

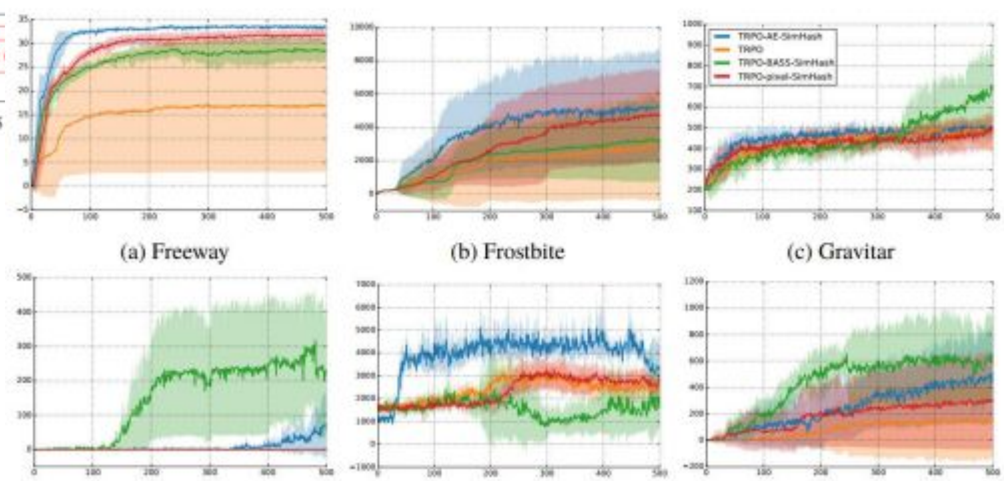

(a) Freeway

(b) Frostbite

(c) Gravitar

(d) Montezuma's Revenge

(e) Solaris

(f) Venture

Оптимизм: модель плотности

Идея: научиться определять, что состояние сильно отличается от ранее посещенных

Можно научить классификатор сравнивать все предыдущие состояния и новое и определять, сильно ли оно отличается.

Вводим два множества:

позитивное: множество, состоящее только из

нового состояния

негативное: все предыдущие состояния

$$p_\theta(\mathbf{s}) = \frac{1 - D_{\mathbf{s}}(\mathbf{s})}{D_{\mathbf{s}}(\mathbf{s})}$$

Обучим на них классификатор

D(s) - вероятность, что классификатор отнесет новое состояние к позитивному

Если s принадлежит негативному множеству, оптимальный D(s) не равен 1

$$D^\star_{\mathbf{s}}(\mathbf{s}) = \frac{1}{1 + p(\mathbf{s})}$$

Сэмплирование Томсона

Храним belief о распределении параметров наград:
$\hat{p}(\theta_1, \dots, \theta_n)$

В model-free RL можно использовать Q-функцию

Общий алгоритм:

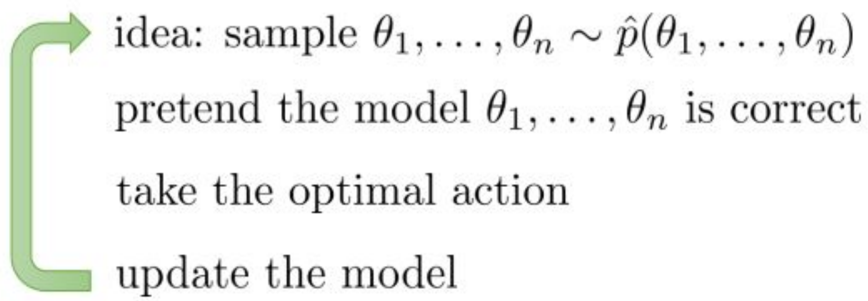

Как представить распределение Q-функций?
Используем bootstrap a $\mathcal{D}$mble: $\mathcal{D}_1, \dots, \mathcal{D}_N$

- Ресемплить датасет N раз, получаем f_{θ_i}
- Обучить на каждом полученном датасете модель
- При сэмплировании выбрать одну из обученных моделей

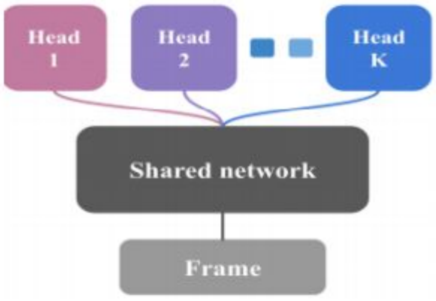

Проблема: обучать N тяжелых нейросетей дорого
Решений: разделить лишь некоторые из слоев:
(Osband et al. “Deep Exploration via Bootstrapped DQN”)

Сэмплирование Томсона

Eps-greedy выбирает либо exploitation, либо действие, независящее от предыдущего

В некоторых задачах это может привести к неразрешимым проблемам

При сэмплировании Томпсона, выбирая случайные Q-функции, однажды мы выберем стратегию, умеющую всплывать (несколько раз плыть вверх)

После того, как одна стратегия научиться всплывать - это распространится на всех

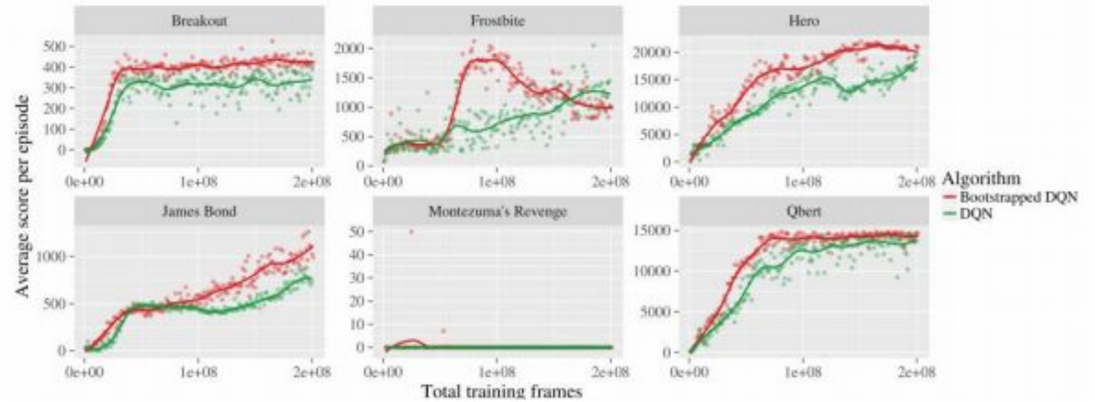

Прирост информации

Байесовский дизайн экспериментов:

Исследуем неизвестную z

Энтропия оценки $\mathcal{H}(\hat{p}(z))$

Энтропия оценки z после наблюдения $\mathcal{H}(\hat{p}(z)|y)$

$$\mathrm{IG}(z, y) = E_y[\mathcal{H}(\hat{p}(z)) - \mathcal{H}(\hat{p}(z)|y)]$$

$$\mathrm{IG}(z, y|a) = E_y[\mathcal{H}(\hat{p}(z)) - \mathcal{H}(\hat{p}(z)|y)|a]$$

Алгоритм для бандитов (Learning to Optimize via Information-Directed Sampling)

$$y = r_a,\ z = \theta_a \ \text{(parameters of model } p(r_a))$$

$$g(a) = \mathrm{IG}(\theta_a, r_a|a) - \text{information gain of } a$$

$$\Delta(a) = E[r(a^\star) - r(a)] - \text{expected suboptimality of } a$$

$$\text{choose } a \text{ according to } \quad \arg\min_a \frac{\Delta(a)^2}{g(a)}$$

Домашнее задание

https://github.com/nadiinchi/dl_labs/blob/master/lab_bandits.ipynb